

# 1 Newton Polynomische Interpolation

## 1.1 Collocation


Collocation = Alle Messpunkte werden von angenäherter Funktion (z.B. Polynom) getroffen. Das Polynom

$$y(x) = p(x) = c_0 + c_1x^1 + c_2x^2 + \dots + c_mx^m \quad \text{mit} \quad y(x_k) = p(x_k) = y_k \quad (k = 0, 1, \dots, n)$$

ergibt ein lineares Gleichungssystem von  $n + 1$  Gleichungen.

## 1.2 Aitken-Neville Rekursionsformel

Sich an den Messpunkten  $x_1, \dots, x_{n-1}$  überlappende polynomiale Interpolationsfunktionen  $f_1 = p_{0,1,\dots,n-1}$ ,  $f_2 = p_{1,\dots,n}$  können zusammengefasst werden.



$$p(x) = p_{0,1,\dots,n}(x) = \frac{(x - x_0) \cdot \overbrace{p_{1,2,\dots,n}(x)}^{\text{green}} - (x - x_n) \cdot \overbrace{p_{0,1,\dots,n-1}(x)}^{\text{red}}}{(x_n - x_0)}$$

## 1.3 Newton Polynome

### Eigenschaften

- + Eingebettet (Wenn ein Messwert dazukommt muss nicht alles neu berechnet werden)
- + Eine einzige Formel
- + Praktisch: Messungen sind gleichverteilt.
- Runge-Phänomen (Schwingungen am Rand)
- Aufwändig zum rechnen

$$y_0 = a_0 \cdot \pi_0$$

↓

$$y_1 = a_0 \cdot \pi_0 + a_1 \cdot \pi_1$$

↓

$$y_2 = a_0 \cdot \pi_0 + a_1 \cdot \pi_1 + a_2 \cdot \pi_2$$

⋮

↓

$$y_n = a_0 \cdot \pi_0(x_n) + a_1 \cdot \pi_1(x_n) + a_2 \cdot \pi_2(x_n) + \dots + a_n \pi_n(x_n)$$

$$\pi_0 = 1$$

$$\pi_1 = (x - x_0)$$

$$\pi_2 = (x - x_0)(x - x_1)$$

⋮

$$\pi_n = (x - x_0)(x - x_1) \dots (x - x_{n-1})$$

$$\pi_{n+1} = (x - x_0)(x - x_1) \dots (x - x_{n-1})(x - x_n)$$

Annäherung an “Messreihe” mit Polynomen:

$$y(x) \approx p(x) = a_0\pi_0(x) + a_1\pi_1(x) + \dots + a_n\pi_n(x)$$

## 1.4 Dividierte Differenzen

Bemerkung:

$$a_{p-1} = y(x_0, x_1, x_2, \dots, x_{p-1}) \text{ gehört zu } \pi_{p-1} = (x - x_0) \cdot (x - x_1) \cdot \dots \cdot (x - x_{p-2})$$

Elegantere und schnellere Auflösung der Newton Polynome.

$$y(x_0, x_1, \dots, x_k) = \frac{y(x_1, x_2, \dots, x_k) - y(x_0, x_1, \dots, x_{k-1})}{(x_k - x_0)} \quad (k = 0, 1, \dots, n)$$

$$a(x_0, \dots, x_n) = \frac{a(x_1, \dots, x_n) - a(x_0, \dots, x_{n-1})}{x_n - x_0}$$

$$k = 0 \quad y(x_0)$$

$$k = 1 \quad \frac{y(x_1) - y(x_0)}{(x_1 - x_0)}$$

$$k = 2 \quad \frac{y(x_1, x_2) - y(x_0, x_1)}{(x_2 - x_0)}$$

$$k = 3 \quad \frac{y(x_1, x_2, x_3) - y(x_0, x_1, x_2)}{(x_3 - x_0)}$$

**Symmetrie:**  $y(x_0, x_1) = y(x_1, x_0) \implies y(x_0, x_1, \dots, x_n)$  ist unabhängig von der Reihenfolge der x-Werte! (Die letzte Differenz  $a_n$  stimmt überein, die anderen Differenzen weichen ab.)

**Beispiel:**

	$x_k$	$y_k$
$x_0$	0	$\textcircled{1} a_0$
$x_1$	1	1 $\textcircled{0} a_1$
$x_2$	2	2 $\textcircled{\frac{1}{2}} a_2$
$x_3$	4	5 $\textcircled{-\frac{1}{12}} a_3$

$$y(x) \approx p(x) = a_0 \cdot \pi_0(x) + a_1 \cdot \pi_1(x) + a_2 \cdot \pi_2(x) + a_3 \pi_3(x)$$

$$= 1 \cdot \pi_0(x) + 0 \cdot \pi_1(x) + \frac{1}{2} \cdot \pi_2(x) - \frac{1}{12} \pi_3(x)$$

$$y(x) \approx p(x) = 1 + \frac{1}{2}(x - x_0)(x - x_1) - \frac{1}{12}(x - x_0)(x - x_1)(x - x_2)$$

$$= 1 + \frac{1}{2}(x - 0)(x - 1) - \frac{1}{12}(x - 0)(x - 1)(x - 2)$$

## 1.5 Collocation Fehlerformel

$$y(x) - p(x) = \frac{y^{(n+1)}(\xi)}{(n+1)!} (x - x_0)(x - x_1) \dots (x - x_{n-1})(x - x_n) = \frac{y^{(n+1)}(\xi)}{(n+1)!} \pi_{n+1}(x) \quad \xi \in (\min(x_i), \max(x_i))$$

Herleitung:  $y = p + \frac{y^{(n+1)}(\xi)}{(n+1)!} \cdot \pi_{n+1} = y(x_0, x_1, \dots, x_n) + \frac{y^{(n+1)}(\xi)}{(n+1)!} \cdot \pi_{n+1} \implies y(x_0, x_1, \dots, x_{n+1}) = \frac{y^{(n+1)}(\xi)}{(n+1)!}$

Der Fehlerterm kann als Ableitung interpretiert werden. Es ist aber nicht klar wo die Ableitung im Bereich  $[x_0, x_n]$  ausgewertet wird, da  $\xi$  nicht bekannt ist!




## 1.6 Runge Phänomen und Chebyshev Argumente

**Runge Phänomen:** Potenzielle Oszillationen an den Definitionsrändern von Polynom-Collocations. Verursacht durch hohe  $n$  und hohe  $\frac{y^{(n+1)}(x)}{(n+1)!}$ .

**Chebyshev-Argumente:** Anpassung der Messpunkte durch andere Verteilung (nicht mehr gleichverteilte  $x_k$ , sondern am Einheitskreis gleichverteilte)

$$x_k = \cos\left(\frac{2k+1}{2(n+1)}\pi\right), \quad (k = 0, 1, \dots, n)$$

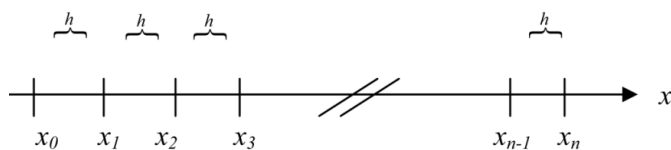
ergibt maximale Amplitude  $\max_{-1 \leq x \leq 1} |\pi_{n+1}(x)| = \frac{1}{2^n}$ . Mit affiner Transformation von Einheitsintervall  $[-1, 1]$  zu  $[a, b]$ :  $x \rightarrow a + \frac{b-a}{2}(x+1)$



### Eigenschaften

- + Kein Runge-Phänomen (Schwingungen am Rand)
- + Eine einzige Formel
- „Nicht eingebettet“ (neue Messungen bedeutet, neue Polynomberechnung!)
- Praktisch: Messungen sind oft nur gleichverteilt möglich (Randauflösung beschränkt)
- Der Bereich der Interpolation ist fixiert (Extrapolation schlecht! (ausserhalb vom Rand))

## 1.7 Gleichverteilte Argumente



$$x_k = x_0 + kh \quad k = 0, 1, 2, \dots, n$$

$$y(x_0, x_1, \dots, x_k) = \frac{\Delta^k y_0}{h^k k!}$$

$$p(x) = y_0 + \frac{\Delta^1 y_0}{h^1 1!} \pi_1(x) + \frac{\Delta^2 y_0}{h^2 2!} \pi_2(x) + \dots + \frac{\Delta^n y_0}{h^n n!} \pi_n(x) = \sum_{k=0}^n \frac{\Delta^k y_0}{h^k k!} \pi_k(x)$$

$\Delta^0$	$y_0$	$y_1$	$y_2$	$y_3$	$y_4$
$\Delta^1$	$y_1 - y_0$	$y_2 - y_1$	$y_3 - y_2$	$y_4 - y_3$	
	$\Delta y_0$	$\Delta y_1$	$\Delta y_2$	$\Delta y_3$	
$\Delta^2$		$\Delta y_1 - \Delta y_0$	$\Delta y_2 - \Delta y_1$	$\Delta y_3 - \Delta y_2$	
		$\Delta^2 y_0$	$\Delta^2 y_1$	$\Delta^2 y_2$	

## 1.8 Taylor Reihe

$$f(x) = y_0 + \underbrace{\frac{y'(x_0)}{1!}(x-x_0) + \frac{y''(x_0)}{2!}(x-x_0)^2 + \dots + \frac{y^{(n)}(x_0)}{n!}(x-x_0)^n}_{\text{Taylor Polynom } p(x)} + \underbrace{\frac{y^{(n+1)}(\xi)}{(n+1)!}(x-x_0)^{n+1}}_{\text{Lagrange Fehlerterm}}$$

## 2 Hermite Interpolation (Osculation)

Erweiterung der dividierten Differenzen: Es sind jetzt auch Ableitungen an Messpunkten als Bedingungen möglich. Aus der Definition von  $y(x)$  ist  $y(x_0, x_0) = y'(x_0)$ . Verallgemeinert ergibt das

$$y(\underbrace{x_0, \dots, x_n, x_{n+1}}_{(n+2)}) = \frac{y^{(n+1)}(\xi)}{(n+1)!}$$

Bsp. HS13/14

$$y(\underbrace{x_0, \dots, x_0}_{(n+1)}) = \lim_{\xi \rightarrow x_0} \frac{y^{(n)}(\xi)}{(n)!} = \frac{y^{(n)}(x_0)}{n!}$$

$$y(x_0, x_1, x_1) = \frac{y(x_1, x_1) - y(x_1, x_0)}{x_1 - x_0} = \frac{y'(x_1) - \frac{y(x_1) - y(x_0)}{x_1 - x_0}}{x_1 - x_0}$$

Für die Hermite Interpolation werden dieselben Newton Tableaus verwendet, aber mit Wiederholungen (siehe Beispiel). Die rot markierten Werte werden wie üblich berechnet.

Wichtig ist, dass bei der Berechnung der dividierten Differenzen keine Löcher entstehen (Ableitungen müssen Lückenlos vorhanden sein (z.B.:  $y', y'', y'''$  good;  $y', y''''$  bad))! Dann ist das Gleichungssystem nicht lösbar! Es kann bei unbestimmten Resultaten eine Variable eingesetzt werden, welche am Schluss ermittelt werden kann.

$x$	$y$
$x_0 = 2$	$y(x_0) = 1$
	$\frac{y^{(1)}(x_0)}{1!} = 1$
$x_0 = 2$	$y(x_0) = 1$
	$\frac{y^{(2)}(x_0)}{2!} = 0$
$x_0 = 2$	$y(x_0) = 1$
	$\frac{y^{(1)}(x_0)}{1!} = 1$
$x_1 = 4$	$y(x_1) = 2$
	$\frac{y^{(1)}(x_1)}{1!} = 0$
$x_1 = 4$	$y(x_1) = 2$
	$\frac{y^{(2)}(x_1)}{2!} = 0$
$x_1 = 4$	$y(x_1) = 2$
	$\frac{y^{(1)}(x_1)}{1!} = 0$

$x$	$y$
2	$\textcircled{1}^{a_0}$
	$\textcircled{1}^{a_1}$
2	1
	$\textcircled{0}^{a_2}$
	1
	$\textcircled{-\frac{1}{8}}^{a_3}$
2	1
	$-\frac{1}{4}$
	$\textcircled{\frac{1}{16}}^{a_4}$
4	2
	$\frac{1}{2}$
	$-\frac{1}{4}$
	$\frac{1}{16}$
4	2
	0
	$\frac{1}{8}$
4	2
	0
	$\textcircled{0}^{a_5}$

Es werden die **modifizierten** Newton Polynome verwendet. In diesem Fall:

---

$\pi_0 = 1$	$\pi_4 = (x - x_0)(x - x_0)(x - x_0)(x - x_1)$
$\pi_1 = (x - x_0)$	$\pi_5 = (x - x_0)(x - x_0)(x - x_0)(x - x_1)(x - x_1)$
$\pi_2 = (x - x_0)(x - x_0)$	$\pi_6 = (x - x_0)(x - x_0)(x - x_0)(x - x_1)(x - x_1)(x - x_1)$
$\pi_3 = (x - x_0)(x - x_0)(x - x_0)$	

---

$$\begin{aligned}
 p_2(x) &= a_0 \cdot \pi_0 + a_1 \cdot \pi_1 + a_2 \cdot \pi_2 + a_3 \cdot \pi_3 + a_4 \cdot \pi_4 + a_5 \cdot \pi_5 \\
 &= a_0 \cdot 1 + a_1 \cdot (x - x_0) + a_2 \cdot (x - x_0)^2 + a_3 \cdot (x - x_0)^3 + a_4 \cdot (x - x_0)^3(x - x_1) + a_5 \cdot (x - x_0)^3(x - x_1)^2 \\
 &= 1 + (x - 2) - \frac{1}{8}(x - 2)^3 + \frac{1}{16}(x - 2)^3(x - 4)
 \end{aligned}$$

## 2.3 Fehlerformel

$$y(x) - p(x) = \frac{y^{(d)}(\xi)}{d!} (x - x_0)^{d_0} (x - x_1)^{d_1} \cdots (x - x_n)^{d_n} \quad x, \xi \in \{\min x_i, \max x_i\} \quad \text{für } i = 0, 1, \dots, 2$$

$d$  ist die total Anzahl Bedingungen und  $d_i$  die Anzahl Bedingungen pro Stützstelle  $x_i$ . ( $d = \sum_{i=0}^n d_i$ )

## 2.4 Fehlende Ableitungen

Bei fehlenden Ableitungsvorgaben werden Variablen eingesetzt und das Tableau mit diesen durchgerechnet. Am Schluss wird von hinten her auf die fehlenden Variablen geschlossen.

### Beispiel:

Gesucht: Polynom 2. Ordnung, welches durch die Punkte  $y(2) = 1$  und  $y(4) = 1$  geht und die Ableitung  $y'(4) = 1$  aufweist.

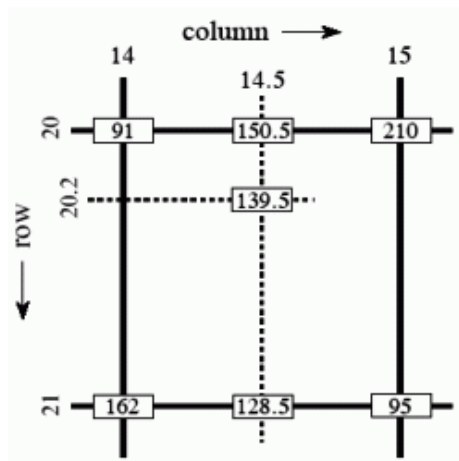
$x$	$y$
2	$\textcircled{1}^{a_0}$
	$\textcircled{\beta}^{a_1}$
2	1 $\textcircled{-\frac{\beta}{2}}^{a_2}$
	0 $\textcircled{\frac{1+\beta}{4}}^{a_3} \stackrel{!}{=} 0$
4	1 $\frac{1}{2}$
	1
4	1

- Weil das Polynom die Ordnung  $d = 2$  aufweisen muss, gilt:  $\frac{1+\beta}{4} = 0$   
Daraus folgt:  $\beta = -1$

- Das Lösungspolynom ist:

$$\begin{aligned}
 p(x) &= a_0 + a_1(x - x_0) + a_2(x - x_0)^2 + a_3(x - x_0)^2(x - x_1) \\
 &= 1 + \beta(x - x_0) - \frac{\beta}{2}(x - x_0)^2 + \frac{1+\beta}{4}(x - x_0)^2(x - x_1) \Big|_{\beta=-1} \\
 &= 1 - (x - 2) + \frac{1}{2}(x - 2)^2
 \end{aligned}$$

### 3 Multi-variate Polynomial Interpolation



1. Die Basis der Polynome kann durch das *2-fold tensor product* berechnet werden  $\Rightarrow$  Bilineare Interpolation

$$\{1, x, x^2\} \otimes \{1, y, y^2\} = \{1, x, y, x^2, y^2, xy, x^2y, xy^2, x^2y^2\};$$

Dadurch kann die Anzahl Gleichungen  $n$  berechnet werden:

$$\mathbb{R}^n \otimes \mathbb{R}^k = \mathbb{R}^{nk}$$

2. Interpolation der gewünschten Ordnung (linear, quadratisch, ...) in X-Richtung an Stelle  $y_0$  berechnen:  $p(x, y_0)$
3. Interpolation der gewünschten Ordnung (linear, quadratisch, ...) in X-Richtung an Stelle  $y_1$  berechnen:  $p(x, y_1)$
4. Tableau für dividierte Differenzen berechnen (hier linearer Fall):

$y$	$z$
$y_0$	$p(x, y_0) = a_{y0}$
$y_1$	$p(x, y_1) \quad \frac{p(x, y_1) - p(x, y_0)}{y_1 - y_0} = a_{y1}$

5. Polynom aufstellen:  

$$p(x, y) = a_{y0}\pi_0(y) + a_{y1}\pi_1(y) + a_{y2}\pi_2(y) + \dots$$
6. Polynom ausmultiplizieren:  

$$p(x, y) = a_{0,0}\pi_0(x)\pi_0(y) + a_{1,0}\pi_1(x)\pi_0(y) + a_{0,1}\pi_0(x)\pi_1(y) + a_{1,1}\pi_1(x)\pi_1(y) + \dots$$

#### 3.1 Beispiel:


Die Punkte  $(14, 20), (14, 21), (15, 20), (15, 21)$  sind gegeben:  $\{91/255, 162/255, 210/255, 95/255\}$ . Gesucht ist eine lineare interpolation. Das ergibt folgende Polynom Basen:  $(\{1, x\} \times \{1, y\} = \{1, x, y, xy\})$

1. Interpolation für  $y = y_0 = 20$ :  $p(x, y_0) = p(x_0, y_0)\pi_0(x) + \frac{p(x_1, y_0) - p(x_0, y_0)}{x_1 - x_0}\pi_1(x) = \frac{1}{255} \left( 91 \cdot 1 + \frac{210 - 91}{15 - 14} \cdot (x - 14) \right)$
2. Das selbe für  $y = y_1 = 21$ :  $p(x, y_1) = \frac{1}{255} \left( 162 \cdot 1 + \frac{95 - 162}{15 - 14} \cdot (x - 14) \right)$
3. Dann die schlussendliche Interpolation:  $p(x, y) = p(x, y_0)\pi_0(y) + \frac{p(x, y_1) - p(x, y_0)}{y_1 - y_0}\pi_1(y)$   

$$= \frac{1}{255} \left( \left( 91 \cdot 1 + \frac{210 - 91}{15 - 14} \cdot 1 \right) \cdot 1 + \frac{162 \cdot \frac{95 - 162}{15 - 14} \cdot (x - 14) - 91 \cdot 1 + \frac{210 - 91}{15 - 14} \cdot (x - 14)}{21 - 20} \cdot (y - 20) \right) = -215.98 + 15.0549x + 10.4902y - 0.7294xy$$

## 4 Spline-Interpolation

Die Idee der Spline-Interpolation ist, die Daten nicht mit einem Polynom hohen Grades zu interpolieren, sondern mit mehreren Polynomen tiefen Grades. Dadurch kann die Tendenz zum Schwingen von Polynomen hohen Grades umgangen werden. Bei den "Bruchstellen", den Übergängen von einem Patch zum nächsten, müssen die Ableitungen der benachbarten Patches bis zu einer vorgegeben Ableitung übereinstimmen.



### Eigenschaften

- + Kein Runge-Phänomen (Schwingungen am Rand)
- + Polynome haben tiefen Grad
- + Aufwand zur Berechnung geringer als Newton [Spline:  $O(n)$  (wegen Tridiagonaler Band-Matrix), Newton:  $O(n^2)$ ]
- „Nicht eingebettet“ (neue Messungen bedeutet, neue Polynomberechnung!)
- Polynome müssen zur Auswertung zusammengesetzt werden (Post-Processing Aufwand gross)

### 4.1 Ein-Dimensionale Splines

#### 4.1.1 Prinzip

Pro *Patch* (von total  $n$ ) wird ein Polynom vom Grad  $d$  (meist kubisch,  $d = 3$ ) berechnet. An den Übergängen bei  $x_i$  können Bedingungen  $C^k$  ( $k = 1, \dots, d - 1$ ) definiert werden.

**Freiheitsgrade**  $n$  Patches mit je 1 Polynom mit je  $(d + 1)$  Koeffizienten, gibt total  $n(d + 1)$  Freiheitsgrade.

**Bedingungen**  $n$  Patches mit Anfang und Ende  $= 2n$ ;  $d - 1$  Ableitungen pro innerem Punkt  $(n - 1)(d - 1)$  ergibt total  $((n(d + 1) - (d - 1)))$  Bedingungen.

**Zusatzbedingungen** Vergleicht man Freiheitsgrade und Bedingungen, sind  $d - 1$  Bedingungen zu wählen. Beim *natural spline* werden dazu die zweiten Ableitungen auf 0 gesetzt; beim *clamped splines* werden die 1. Ableitungen vorgegeben.

#### 4.1.2 Allgemeines Vorgehen (kubische Splines)

Die endgültige Interpolation hat folgende Form (Beschreibung **eines** Patches):

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3$$

$$S'_i = b_i + 2c_i(x - x_i) + 3d_i(x - x_i)^2$$

$$S''_i = 2c_i + 6d_i(x - x_i)$$

Gebraucht wird auch (Patch-Breite)  $h_i = x_{i+1} - x_i = \Delta x_i$

1.  $a_i = y_i$  ( $i = 0, \dots, n - 1$ )
2. Für kubische Splines hat es  $d - 1 = 3 - 1 = 2$  Zusatzbedingungen.

$$\begin{pmatrix} h_0 & 2(h_0 + h_1) & h_1 & & & \\ & h_1 & 2(h_1 + h_2) & h_2 & & \\ & & h_2 & 2(h_2 + h_3) & h_3 & \\ & & & \ddots & \ddots & \ddots \\ & & & & h_{n-3} & 2(h_{n-3} + h_{n-2}) & h_{n-2} \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ c_2 \\ \vdots \\ c_{n-2} \\ c_{n-1} \end{pmatrix} = \begin{pmatrix} 3 \left( \frac{y_{i+1} - y_i}{h_i} - \frac{y_i - y_{i-1}}{h_{i-1}} \right) \end{pmatrix}_{i=1, \dots, n-2}$$

- **Natural Splining** (Randkrümmung):  $y_0'' = 0 = y_n''$  (minimiert das Energiemass! ( $\min \int |f''(x)|^2 dx$ ))

(a)  $c_0 = c_n = 0$

(b) Gleichungssystem nach  $c_i$  auflösen:

$$\begin{pmatrix} 2(h_0+h_1) & h_1 & & & & \\ h_1 & 2(h_1+h_2) & h_2 & & & \\ & h_2 & 2(h_2+h_3) & h_3 & & \\ & & \ddots & \ddots & \ddots & \\ & & & h_{n-3} & 2(h_{n-3}+h_{n-2}) & h_{n-2} \\ & & & & h_{n-2} & 2(h_{n-2}+h_{n-1}) \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ c_3 \\ \vdots \\ c_{n-2} \\ c_{n-1} \end{pmatrix} = \begin{pmatrix} 3 \left( \frac{y_{i+1}-y_i}{h_i} - \frac{y_i-y_{i-1}}{h_{i-1}} \right) \\ \vdots \\ 3 \left( \frac{y_{i+1}-y_i}{h_i} - \frac{y_i-y_{i-1}}{h_{i-1}} \right) \end{pmatrix}_{i=1, \dots, n-1}$$

- **Clamped Splining:**

(a)  $b_0 = y_0'; b_n = y_n'$

(b) Gleichungssystem nach  $c_i$  auflösen:

$$\begin{pmatrix} 2h_0 & h_0 & & & & \\ h_0 & 2(h_0+h_1) & h_1 & & & \\ & h_1 & 2(h_1+h_2) & h_2 & & \\ & & h_2 & 2(h_2+h_3) & h_3 & \\ & & \ddots & \ddots & \ddots & \\ & & & h_{n-3} & 2(h_{n-3}+h_{n-2}) & h_{n-2} \\ & & & & 2h_{n-2} & 4h_{n-2}+3h_{n-1} \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \\ c_2 \\ \vdots \\ c_{n-2} \\ c_{n-1} \end{pmatrix} = \begin{pmatrix} 3 \left( \frac{a_1-a_0}{h_0} - y_0' \right) \\ \vdots \\ 3 \left( \frac{y_{i+1}-y_i}{h_i} - \frac{y_i-y_{i-1}}{h_{i-1}} \right) \\ \vdots \\ 9 \frac{y_n-a_{n-1}}{h_{n-1}} - 6 \frac{a_{n-1}-a_{n-2}}{h_{n-2}} - 3y_n' \end{pmatrix}_{i=1, \dots, n-2}$$

$$3. \quad b_{i-1} = \frac{a_i-a_{i-1}}{h_{i-1}} - \frac{2c_{i-1}+c_i}{3} h_{i-1} \quad (i = 1, \dots, n-1)$$

$$4. \quad b_{n-1} = \frac{y_n-a_{n-1}}{h_{n-1}} - c_{n-1} h_{n-1} - d_{n-1} h_{n-1}^2 = \frac{y_n-y_{n-1}}{h_{n-1}} - \frac{2}{3} c_{n-1} h_{n-1}$$

$$5. \quad d_{i-1} = \frac{c_i-c_{i-1}}{3h_{i-1}} \quad (i = 1, \dots, n-1)$$

$$6. \quad \text{Clamped splining: } d_{n-1} = \frac{y_n'-b_{n-1}-2c_{n-1}h_{n-1}}{3h_{n-1}^2} \quad \text{Natural Splining: } d_{n-1} = -\frac{c_{n-1}}{3h_{n-1}}$$

## Weitere Methoden

Bei *Hermite cubic splines* werden  $C^1$ -Funktionen aus gepatchten kubischen Polynomen mit vorgegebenen ersten Ableitungen gebildet.

*Periodic splines* sind  $C^2$  Funktionen aus gepatchten kubischen Polynomen mit Periodizität ( $S'(x_0) = S'(x_n)$  und  $S''(x_0) = S''(x_n)$ ).

### 4.1.3 Fehlerabschätzung

Für kubische Splines mit  $C^2$  gilt folgende Fehlerabschätzung ( $H = \max h_i$  ( $i = 0, \dots, n-1$ )):

$$|y(x) - S(x)| \leq \max |y^{(4)}(x)| \frac{5}{384} H^4 \quad |y'(x) - S'(x)| \leq \max |y^{(4)}(x)| \frac{1}{24} H^3 \quad |y''(x) - S''(x)| \leq \max |y^{(4)}(x)| \frac{3}{8} H^2$$






### 4.2.3 Casteljau recurrence

Die Casteljau recurrence ist eine ähnliche Idee wie Neville-Aitken. Damit kann ein Punkt auf einer Bézier Kurve als Linearkombination zweier Punkte aus Bézier Kurven tieferer Ordnung berechnet werden.

$$\vec{r}_{\vec{P}_0, \vec{P}_1, \dots, \vec{P}_n}(t) = (1-t) \cdot \vec{r}_{\vec{P}_0, \vec{P}_1, \dots, \vec{P}_{n-1}}(t) + t \cdot \vec{r}_{\vec{P}_1, \vec{P}_2, \dots, \vec{P}_n}(t) \quad t \in [0, 1]$$

### 4.2.4 Zusammengesetzte (Composite) Bézier Kurven

Die zusammengesetzten (simply) Bézier-Kurven sollen die bekannte Bedingungen ( $C^k$ ) erfüllen. Dies sind die Gleichungen um den Punkt  $Q_0$  mit Kontrollpunkten  $Q_1, \dots, m-1$  nach  $Q_0$  sowie den Kontrollpunkten  $P_1, \dots, n-1$  vor  $Q_0$ .



Hier sind  $m = n = 3$

$$\begin{array}{ll} C^0 : & \boxed{\vec{P}_n = \vec{Q}_0} \\ C^1 : & \vec{r}'_P(1) = \boxed{n(\vec{P}_n - \vec{P}_{n-1}) = m(\vec{Q}_1 - \vec{Q}_0)} = \vec{r}'_Q(0) \\ C^2 : & \vec{r}''_P(1) = \boxed{n(n-1)(\vec{P}_n - 2\vec{P}_{n-1} + \vec{P}_{n-2}) = m(m-1)(\vec{Q}_2 - 2\vec{Q}_1 + \vec{Q}_0)} = \vec{r}''_Q(0) \\ C^k : & \vec{r}^{(k)}_P(1) = \boxed{n(n-1) \dots (n-k+1)(\Delta^k \vec{P}_{n-k}) = m(m-1) \dots (m-k+1)(\Delta^k \vec{Q}_0)} = \vec{r}^{(k)}_Q(0) \end{array}$$

$m$  ist dabei der Grad von  $\vec{r}_Q$ ,  $n$  derjenige von  $\vec{r}_P$ .

### 4.2.5 Zusammengesetzte (Composite) Bézier Kurven mit $P_{i,j}$

Wird  $\vec{r}_j(t) = \sum_{i=0}^n \vec{P}_{i,j} B_{i,n}(t)$   $t \in [0, 1]$  mit den Fixpunkten  $Q_j$  definiert (Grad:  $n$ ), ergeben sich folgende Formeln:

$$\begin{array}{ll} C^0 : & \boxed{\vec{P}_{n,j-1} = \vec{P}_{0,j} = \vec{Q}_j} \\ C^1 : & \vec{r}'_{j-1}(1) = \boxed{\vec{Q}_j - \vec{P}_{n-1,j-1} = \vec{P}_{1,j} - \vec{Q}_j} = \vec{r}'_j(0) \\ C^2 : & \vec{r}''_{j-1}(1) = \boxed{\vec{Q}_j - 2\vec{P}_{n-2,j-1} + \vec{P}_{n-1,j-1} = \vec{P}_{2,j} - 2\vec{P}_{1,j} + \vec{Q}_j} = \vec{r}''_j(0) \\ C^k : & \vec{r}^{(k)}_{j-1}(1) = \boxed{\Delta^k \vec{P}_{n-k,j-1} = \Delta^k \vec{P}_{0,j}} = \vec{r}^{(k)}_j(0) \end{array}$$

### 4.2.6 Bézier Oberflächen als Tensor Splines

Bézier Oberflächen werden gleich wie Bézier Kurven mittels einem Tensorprodukt aus Bernstein Polynomen gebildet. Eine Oberfläche im Intervall  $[0, 1] \times [0, 1]$  wird gebildet durch

$$\vec{z}(s, t) = \sum_{i=0}^n \sum_{j=0}^m \vec{P}_{ij} B_{in}(s) B_{jm}(t) \quad s, t \in [0, 1]$$

Details und Formeln siehe Skript S. 19 – 23.

### 4.2.7 Vergleich Bézier- und Newton-Interpolation mit gleichverteilten Argumenten auf X-Achse

Aus Sicht Bézier:

- + Kleiner Fehler, keine Oszillation, kein Runge (bei kleinem Grad, z.B. 3)
- +  $O(n)$  (linearer Rechenaufwand)
- Nicht eingebettet (neue Daten brauchen Neuberechnung der Interpolation)
- Post-Processing (Grafik, Integrations, Ableitungen) sind komplexer, da jedes Kurvenstück einzeln betrachtet werden muss.

## 5 Least-Squares Approximation

### 5.1 Lineare Least-Squares

Ziel: Approximation von Messpunkten durch Minimieren einer Funktion, die die Abweichung in  $y$  angibt (Residuen). Die Datenpunkte werden bei dieser Methode nicht mehr genau getroffen, ausserdem ist der Grad  $m$  des Approximation-Polynoms meist massiv kleiner als die Anzahl der gegebenen Datenpunkte  $N + 1$ .

Aus einer Menge von Basisfunktionen  $g_0, g_1, \dots, g_m$  mit  $m \ll N$  und den Messungen  $(x_0, y_0), (x_1, y_1), \dots, (x_N, y_N)$  wird das überdeterminierte ( $m < N$ ) Gleichungssystem aufgestellt und nach den unbekannten  $a_i$  gelöst.

$$\overbrace{\begin{pmatrix} g_0(x_0) & g_1(x_0) & \dots & g_m(x_0) \\ \vdots & \vdots & \ddots & \vdots \\ g_0(x_N) & g_1(x_N) & \dots & g_m(x_N) \end{pmatrix}}^{\text{Designmatrix } G} \cdot \begin{pmatrix} a_0 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} y_0 \\ \vdots \\ y_N \end{pmatrix} \Leftrightarrow G \cdot a = y$$

Zu minimierende Fehlerfunktion:


$$\underbrace{S}_{\text{Fehler}} = \sum_{i=0}^N \left( y_i - \underbrace{\sum_{j=0}^m a_j g_j}_{\text{Modell}} \right)^2 = \sum_{i=0}^N r_i^2$$

Modellfunktion:

$$y = \sum_{j=0}^m a_j g_j \stackrel{\text{Poly!}}{=} \sum_{j=0}^m a_j x^j$$

Abweichungen (Residuen):

$$r_i = y_i - \sum_{j=0}^m a_j g_j$$




#### 5.1.1 Normalgleichung

Minimieren des quadratischen Fehlers mit „Normalmatrix“  $G$  (Designmatrix):

$$\underbrace{G^T G}_{\text{Normalmatrix}} \cdot a = G^T y \Rightarrow a = (G^T G)^{-1} G^T y$$

$$\underbrace{\begin{pmatrix} G^T \\ (m+1) \times (N+1) \end{pmatrix}}_{(m+1) \times (m+1)} \cdot \underbrace{\begin{pmatrix} G \\ (N+1) \times (m+1) \end{pmatrix}}_{(N+1) \times (m+1)} \cdot \underbrace{a}_{(m+1) \times 1} = \underbrace{\begin{pmatrix} G^T \\ (m+1) \times (N+1) \end{pmatrix}}_{(m+1) \times (N+1)} \cdot \underbrace{y}_{(N+1) \times 1}$$



Die symmetrische  $(m+1) \times (m+1)$  Matrix  $G^T \cdot G$  ist positiv definit wenn  $g_i$  linear unabhängig sind. Das neue Gleichungssystem ist regulär und hat eine eindeutige Lösung für die Koeffizienten  $a_j$ .

$$\overbrace{\begin{pmatrix} \langle g_0 | g_0 \rangle & \langle g_1 | g_0 \rangle & \dots & \langle g_m | g_0 \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle g_0 | g_m \rangle & \langle g_1 | g_m \rangle & \dots & \langle g_m | g_m \rangle \end{pmatrix}}^{G^T \cdot G} \cdot \begin{pmatrix} a_0 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} \langle y | g_0 \rangle \\ \vdots \\ \langle y | g_m \rangle \end{pmatrix}$$

#### 5.1.2 QR-Zerlegung

Eine quadratische  $n \times n$  Matrix  $Q$  ist orthogonal, falls  $Q^T \cdot Q = Q \cdot Q^T = I$  bzw.  $Q^T = Q^{-1}$ . Jede beliebige Matrix  $G$  mit den Dimensionen  $(N+1) \times (m+1)$  mit  $N \geq m$  und Rang  $m+1$  kann als Produkt einer orthogonalen  $(N+1) \times (N+1)$  Matrix  $Q$  und einer  $(N+1) \times (m+1)$  oberen Dreiecksmatrix  $R$ .

Aus dem Gleichungssystem  $Ga = y$  wird dann  $Ra = Q^T y$ , was einfacher lösbar ist<sup>Citation needed</sup>.

### 5.1.3 Singulärwertzerlegung (singular value decomposition, SVD)

Jede Matrix  $\mathbf{G}$  mit Dimensionen  $(N+1) \times (m+1)$  kann so zerlegt werden:

$$\mathbf{G} = \mathbf{U} \mathbf{D} \mathbf{V}^T = \mathbf{U} \cdot \begin{bmatrix} d_{00} & 0 & \dots & 0 \\ 0 & d_{11} & \dots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & \dots & 0 & d_{mm} \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \dots & 0 \end{bmatrix} \cdot \mathbf{V}^T$$

$\mathbf{D}$   $((N+1) \times (m+1))$  ist die zentrale Diagonalmatrix mit Singulärwerten,  $\mathbf{U}$   $((N+1) \times (N+1))$  und  $\mathbf{V}$   $((m+1) \times (m+1))$  sind orthogonale und quadratische Matrizen (d.h. u.a.  $\mathbf{U}^T = \mathbf{U}^{-1}$ ).

Die Zerlegung an sich wird hier nicht weiter ausgeführt, diese kann anderswo nachgeschlagen werden. SVD kann gebraucht werden, um Gleichungssystem zu lösen (wie hier), um Eigenvektoren und Eigenwerte sowie die Inverse zu berechnen.

Aus  $Ga = y$  wird  $UDV^T a = y$ . Dies lässt sich auflösen zu

$$a = VD^{-1}U^T \cdot y$$

### 5.1.4 Monomiale

Mit  $g = a_0 \underbrace{1}_{g_0} + a_1 \underbrace{x}_{g_1} + a_2 \underbrace{x^2}_{g_2} + \dots + a_m \underbrace{x^m}_{g_2}$  wird die Designmatrix zu:

$$\mathbf{G} = \underbrace{\begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^m \\ 1 & x_1 & x_1^2 & \dots & x_1^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_N & x_N^2 & \dots & x_N^m \end{bmatrix}}_{\text{When Monomials}}$$

### 5.1.5 Gleichförmige Argumente (Orthogonalitäts-Eigenschaften)

Mit gleichförmigen Elementen  $x_i - x_j = (j-i)h$  für alle  $i, j \rightarrow \{x_0 \dots x_N\} = \{x_0 + t \cdot h\}_{t=0 \dots N}$  und **orthogonalen Polynomen** kann  $GG^T$  diagonalisiert und so die Gleichungen rechnerisch einfacher gelöst werden.

$$p_{k,N}(t) = \sum_{i=0}^k (-1)^i \binom{k}{i} \binom{k+i}{i} \frac{t^{(i)}}{N^{(i)}} = 1 + \sum_{i=1}^k (-1)^i \binom{k}{i} \binom{k+i}{i} \frac{t(t-1)(t-2) \dots (t-i+1)}{N(N-1)(N-2) \dots (N-i+1)} \quad (k=1, \dots, N)$$

mit  $t = \frac{x-x_0}{h}$   $\binom{k}{i} = \frac{k!}{i!(k-i)!} = nCr(k, i)$

$p_{k,N}$  kann jetzt als  $g_k$  in die Designmatrix eingesetzt werden und das Produkt  $G^T G$  wird zu einer  $(m+1) \times (m+1)$  Diagonalmatrix. Schlussendlich kann  $a$  über die bekannte Formel  $G^T Ga = G^T y$  berechnet werden.

**Beispiel:**

$$\begin{aligned} \mathbf{x} &= \begin{bmatrix} 3 & 4 & 5 & 6 & 7 \end{bmatrix} \Rightarrow \mathbf{t} = \mathbf{x} - 3 = \begin{bmatrix} 0 & 1 & 2 & 3 & 4 \end{bmatrix} \\ \Rightarrow P_0(x) &= 1 \quad P_1(x) = 1 - \frac{x-3}{2} \quad P_2(x) = 1 - \frac{2 \cdot 3(x-3)}{4} + \frac{1 \cdot 3(x-3)(x-3-1)}{4 \cdot 3} = 1 - \frac{3x-9}{2} + \frac{1}{2}(x-4)(x-3)??? \\ \mathbf{G} &= \begin{bmatrix} P_0 & P_1 & P_2 \\ 1 & 1 & 1 \\ 1 & 1/2 & -1/2 \\ 1 & 0 & -1 \\ 1 & -1/2 & -1/2 \\ 1 & -1 & 1 \end{bmatrix} \Rightarrow \mathbf{G}^T \mathbf{G} = \begin{bmatrix} \|P_0\|^2 & 0 & 0 \\ 0 & \|P_1\|^2 & 0 \\ 0 & 0 & \|P_2\|^2 \end{bmatrix} = \begin{bmatrix} 5 & 0 & 0 \\ 0 & \frac{5}{2} & 0 \\ 0 & 0 & \frac{7}{2} \end{bmatrix} \end{aligned}$$

### 5.1.6 Chebyshev Orthogonale Polynome

**Idee:** Approximation eines kontinuierlichen Polynoms durch Chebyshev-Polynome.

**Definition**

Chebyshev Polynome sind definiert als  $T_n(x) = \cos(n \arccos(x))$  mit  $(n = 0, 1, \dots)$  und  $(-1 \leq x \leq 1)$ . Dieses Polynom bewirkt eine Häufung der Messwerte in den Randbereichen. Die ersten paar Polynome  $T_n$  sowie deren Umformungen nach  $x$ :

$$\begin{aligned} T_0 &= 1 & x^0 &= 1 = T_0 \\ T_1 &= x & x^1 &= x = T_1 \\ T_2 &= 2x^2 - 1 & x^2 &= \frac{1}{2}T_2 + \frac{1}{2}T_0 \\ T_3 &= 4x^3 - 3x & x^3 &= \frac{1}{4}T_3 + \frac{3}{4}T_1 \\ T_4 &= 8x^4 - 8x^2 + 1 & x^4 &= \frac{1}{8}T_4 + \frac{1}{2}T_2 + \frac{3}{8}T_0 \\ T_5 &= 16x^5 - 20x^3 + 5x & x^5 &= \frac{1}{16}T_5 + \frac{5}{16}T_3 + \frac{5}{8}T_1 \end{aligned}$$

Weitere Chebyshev Polynome können mit der Rekursionsformel  $T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x)$  ( $n \geq 2$ ) mit Initialbedingungen  $T_1(x) = x$ ,  $T_0(x) = 1$  berechnet werden.

**Eigenschaften:**

- Die maximale Amplitude des Chebyshev-Polynoms ist  $\frac{1}{2^n}$  (max Amplitude des Fehlerterms).
- Amplitude:  $T_n(x) \in [-1, +1]$
- Nullstellen:  $T_n(x) = 0 \Leftrightarrow x = \cos(\frac{2i+1}{2n}\pi)$  ( $i = 0, 1, \dots, n-1$ ) (Diese Nullstellen sind die Chebyshev-Knoten)
- $T_n(x) = \pm 1 \Leftrightarrow x = \cos(\frac{i\pi}{n})$  ( $i = 0, 1, \dots, n$ )

**Rezept**

Chebyshev Polynome können nur benutzt werden, wenn  $x$  mit **Chebyshev-Abständen**  $x_i = \cos(\frac{2i+1}{2n}\pi)$  ( $i = 0, 1, \dots, n-1$ ) und nicht mit gleichverteilten Abständen gewonnen wurden.

Ziel:  $y(t) = p_N(t)$  (Polynom, definiert in  $[a, b]$ ) mit Chebyshev-Polynomen des Grades  $m$  approximieren.

1.  $y(t)$  auf das Standardintervall  $[-1, 1]$  normieren (affine Transformation)  $t = a + \frac{b-a}{2}(x+1)$ .
2.  $y(x)$  aus  $T_n$  zusammensetzen
3.  $y(x)$  auf Grad  $m$  kürzen (truncate):  $y_m(x)$
4. Zurücktransformieren:  $x = 2\frac{t-a}{b-a} - 1$
5.  $T_n$  in  $y_m$  einsetzen (siehe Tabelle oben)
6. Fehlerabschätzung für truncate Methode:  
 $\max_t |y(t) - y_m(t)|$  (Abgeschnittener Teil)

**Beispiel**

Gesucht: Approximation  $y(t) = t^3$  mit Grad  $m = 2$  für Intervall  $(a, b) = (0, 1)$

1. Transformation mit  $t = \frac{x+1}{2}$ :  
 $y(x) = (\frac{x+1}{2})^3 = \frac{1}{8}(x^3 + 3x^2 + 3x + 1)$
2. Mit Tabelle erweitern:  
 $y(x) = \frac{1}{8} \left( \frac{T_3(x)+3T_1(x)}{4} + 3\frac{T_2(x)+T_0}{2} + 3T_1(x) + T_0(x) \right)$   
 $= \frac{1}{32}T_3(x) + \frac{3}{16}T_2(x) + \frac{15}{32}T_1(x) + \frac{5}{16}T_0(x)$
3. Kürzen auf Grad  $m = 2$ :  
 $y(x) \approx \frac{3}{16}T_2(x) + \frac{15}{32}T_1(x) + \frac{5}{16}T_0(x)$
4. Zurücktransformieren mit  $x = 2t - 1$ :  
 $y(t) \approx \frac{3}{16}T_2(2t-1) + \frac{15}{32}T_1(2t-1) + \frac{5}{16}T_0(2t-1)$
5.  $T_n(2t-1)$  ersetzen:  
 $y(t) \approx \frac{3}{16}(2(2t-1)^2 - 1) + \frac{15}{32}(2t-1) + \frac{5}{16}$
6. Fehlerabschätzung:  
 $\max_t \left| \frac{1}{32}T_3(2t-1) \right|$

Die **Designmatrix** sieht so aus:

$$G \underset{\substack{= \\ \text{When Chebyshev}}}{=} \begin{bmatrix} T_0(x_0) = 1 & T_1(x_0) = x_0 & \dots & T_m(x_0) \\ T_0(x_1) = 1 & T_1(x_1) = x_1 & \dots & T_m(x_1) \\ \vdots & \vdots & \ddots & \vdots \\ T_0(x_N) = 1 & T_1(x_N) = x_N & \dots & T_m(x_N) \end{bmatrix}_{N \times m}$$

Damit wird  $G^T G$  zu:

$$G^T G \underset{\substack{= \\ \text{When Chebyshev}}}{=} \begin{bmatrix} N+1 & 0 & \dots & 0 \\ 0 & \frac{N+1}{2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \frac{N+1}{2} \end{bmatrix}_{m \times m}$$

und  $(G^T G)^{-1} G^T$  zu:

$$(G^T G)^{-1} G^T \underset{\substack{= \\ \text{When Chebyshev}}}{=} \begin{bmatrix} \frac{1}{N+1} T_0(x_0) = \frac{1}{N+1} & \frac{1}{N+1} T_0(x_1) = \frac{1}{N+1} & \dots & \frac{1}{N+1} T_0(x_N) = \frac{1}{N+1} \\ \frac{2}{N+1} T_1(x_0) = \frac{2}{N+1} x_0 & \frac{2}{N+1} T_1(x_1) = \frac{2}{N+1} x_1 & \dots & \frac{2}{N+1} T_1(x_N) = \frac{2}{N+1} x_N \\ \vdots & \vdots & \ddots & \vdots \\ \frac{2}{N+1} T_m(x_0) & \frac{2}{N+1} T_m(x_1) & \dots & \frac{2}{N+1} T_m(x_N) \end{bmatrix}_{m \times N}$$

### 5.1.7 Diskrete Least-Squares Chebyshev Approximation

Folgt aus  $a = (G^T G)^{-1} G^T y$  für  $x_i = \cos(\frac{2i+1}{2(N+1)}\pi)$  ( $i = 0, 1, \dots, N$ ):

$$p(x) = \sum_{j=0}^m a_j T_j(x) \quad \text{wobei} \quad a_j = \begin{cases} \frac{1}{N+1} \sum_{i=0}^N y(x_i) & j = 0 \\ \frac{2}{N+1} \sum_{i=0}^N T_j(x_i) y(x_i) & j > 0 \end{cases}$$

### 5.1.8 Kontinuierliche Least-Squares

Für kontinuierliche Funktionen, die **keine Polynome** sind (!) kann auch die kontinuierliche Version verwendet werden.  
S: zu minimierende Fehlerfunktion, w: Gewicht mit  $(-1 \leq x \leq 1)$

$$S = \int_{-1}^1 (y(x) - p(x))^2 \cdot w(x) \cdot dx$$

### Kontinuierliche Least-Squares Chebyshev Approximation

Das Gewicht wird besonders auf den Rand gelegt (wie bei Chebyshev üblich). ( $w(x) = \frac{1}{\sqrt{1-x^2}}$ )

$$p(x) = \sum_{j=0}^m a_j T_j(x) \quad \text{wobei} \quad a_j = \begin{cases} \frac{1}{\pi} \int_{-1}^1 \frac{y(x)}{\sqrt{1-x^2}} dx & j = 0 \\ \frac{2}{\pi} \int_{-1}^1 \frac{y(x) T_j(x)}{\sqrt{1-x^2}} dx & j > 0 \end{cases}$$

### Kontinuierliche Least-Squares Legendre Approximation:

Hier bei wird das Gewicht  $w(t) = 1$  gesetzt.

Legendre Polynome:

$$\begin{aligned} P_n(x) &= \frac{1}{2^n n!} \cdot \frac{d^n}{dx^n} (x^2 - 1)^n & P_0(x) &= 1 & P_1(x) &= x & P_2(x) &= \frac{1}{2}(3x^2 - 1) \\ P_3(x) &= \frac{1}{2}(5x^3 - 3x) & P_4(x) &= \frac{1}{8}(35x^4 - 30x^2 + 3) & P_5(x) &= \frac{1}{8}(63x^5 - 70x^3 + 15x) \\ 1 &= P_0(x) & x &= P_1(x) & x^2 &= \frac{2P_2(x) + P_0(x)}{3} & x^3 &= \frac{2P_3(x) + 3P_1(x)}{5} & x^4 &= \frac{8P_4(x) + 20P_2(x) + 7P_0(x)}{35} \end{aligned}$$

Koeffizienten:

$$p(x) = \sum_{j=0}^m a_j P_j(x) \quad \text{wobei} \quad a_j = \frac{2j+1}{2} \cdot \int_{-1}^1 y(x) P_j(x) \cdot dx \quad (j = 0, 1, \dots, m)$$

## 5.2 Multi-Variate Linear Least Squares Approximation

Multi-Variate Least Square Probleme werden genau gleich wie die Uni-Variaten Least Square Probleme gelöst (selbe Methoden)! Die Variable  $x$  ist keine Zahl mehr, sondern ein Vector mit  $d$  Dimensionen!

**Basisgewinnung:** Die Basen werden mittel Tensorenprodukt aus Uni-Variaten Basen berechnet (Alle mit allen Multiplizieren (d-Basen in d-Variablen)).

$$\sum_{j_1=0}^{m_1} \sum_{j_2=0}^{m_2} \dots \sum_{j_d=0}^{m_d} a_{j_1, j_2, \dots, j_d} \cdot g_{j_1}(x^{(1)}) g_{j_2}(x^{(2)}) \cdot \dots \cdot g_{j_d}(x^{(d)})$$

### Beispiele

Basis 3. Grad:  $\{1, x, y, x^2, 2xy, x^2, x^3, 3x^2y, 3xy^2, y^3\}$

Basis 4. Grad:  $\{1, x, y, x^2, 2xy, x^2, x^3, 3x^2y, 3xy^2, y^3, x^4, 4x^3y, 6x^2y^2, 4xy^3, y^4\}$

### 5.2.1 Matrix Condition Number

Gegeben sei ein Lineares Gleichungssystem der Form  $Ax = b$  mit der Lösung  $x = A^{-1}b$ . Die Condition Number  $\kappa(A)$  misst den maximalen relativen Fehler der Lösung  $x$  in Bezug auf den relativen Fehler der rechten Seite  $b$ :

$$\kappa(A) = \begin{cases} \max\left(\frac{\|\Delta x\|/\|x\|}{\|\Delta b\|/\|b\|}\right) & b \neq 0, \Delta b \neq 0, Ax = b \text{ if the matrix } A \text{ is regular} \\ \infty & \text{otherwise} \end{cases}$$

wobei  $\|\dots\|$  für eine Vektornorm, normalerweise die Euklidische Norm  $\|\dots\|_2$  oder die maximale Norm  $\|\dots\|_\infty$ , steht. Wenn  $\kappa(A)$  relativ klein ist, wird das System/die Matrix "well-conditioned" genannt, ansonsten ist sie "ill-conditioned". Für eine reguläre Matrix  $A$  und die Euklidische Norm  $\|\dots\|_2$ :

- $\kappa(A) = \frac{|\sigma_{max}|}{|\sigma_{min}|}$ ,  $|\sigma_{max}|$  = absoluter maximaler Singulärwert und  $|\sigma_{min}|$  = absoluter minimaler Singulärwert von  $A$
- Falls  $A$  zusätzlich eine Normalmatrix ist:  $\kappa(A) = \frac{|\lambda_{max}|}{|\lambda_{min}|}$ ,  $|\lambda_{max}|$  = absoluter maximaler Eigenwert und  $|\lambda_{min}|$  = absoluter minimaler Eigenwert

## 6 Fehlerfortpflanzung

### 6.1 Differential

Das Differential  $df$  bezeichnet den linearen Anteil des Zuwachses einer Variablen einer Funktion.

$$\Delta f = f(x_0 + h) - f(x_0) \approx df = f'(x_0)dx = f'(x_0)h = f'(x_0)\Delta x$$

$\Delta f$  ist der *absolute* Fehler von  $f$  bei  $x_0$ . Der *relative* Fehler ist  $\frac{\Delta f}{f} \approx \frac{df(x_0)}{f(x_0)}$ . Jede  $n$ -fach ableitbare Funktion kann mit einer **Taylor**-Reihe approximiert werden:

$$f(x_0 + h) = f(x_0) + hf'(x_0) + \frac{h^2}{2}f''(x_0) + \frac{h^3}{3!}f'''(x_0) + \dots + \frac{h^n}{n!}f^{(n)}(x_0) + R_n(x_0, h)$$

Wobei  $R_n(x_0, h)$  das Restglied bezeichnet und mit  $n \rightarrow \infty$  gegen 0 mit Geschwindigkeit  $o(h^n)$  („schnell“) konvergiert. Es gibt bspw. die

$$\text{Lagrange Form: } R_n(x_0, h) = \frac{h^{n+1}}{(n+1)!} f^{(n+1)}(\underbrace{x_0 + \vartheta h}_{\xi}) \quad (\xi \in (x_0, x_0 + h), \vartheta \in (0, 1)) \quad \text{oder die}$$

$$\text{Cauchy Form: } R_n(x_0, h) = \frac{h^n(1-\vartheta)^n}{(n+1)!} f^{(n+1)}(\underbrace{x_0 + \vartheta h}_{\xi}) \quad (\xi \in (x_0, x_0 + h), \vartheta \in (0, 1))$$

Mit der Taylor-Reihe wird der absolute Fehler zu

$$\Delta f = \frac{1}{1!}df(x_0) + \frac{1}{2!}d^2f(x_0) + \dots + \frac{1}{n!}d^nf(x_0) + R_n(x_0, h)$$

### 6.2 Multivariate Differentiale, Taylor

Das Differential sieht im Multidimensionalen so aus:

$$\Delta f \approx df(\vec{x}) = \sum_{i=1}^n \frac{\partial f(\vec{x})}{\partial x_i} h_i = h_1 \frac{\partial f(\vec{x})}{\partial x_1} + \dots + h_n \frac{\partial f(\vec{x})}{\partial x_n} \quad \text{mit } \vec{h} = [h_1, \dots, h_d]^T, \vec{x} = [x_1, \dots, x_d]^T$$

Das Vektorfeld der partiellen Ableitungen wird das Gradientenfeld von  $f$  genannt und mit  $\text{grad}(f)$  oder  $\vec{\nabla} f(\vec{x})$  bezeichnet. Damit ist  $\Delta f \approx \vec{\nabla} f(\vec{x}) \cdot \vec{h}$ .

Im Multi-variaten Fall wird die Taylor-Reihe für Multiindizes  $\alpha = \{\alpha_1, \dots, \alpha_n\}$  und  $|\alpha| = \alpha_1 + \dots + \alpha_n$  zu

$$f(\vec{x}_0 + \vec{h}) = f(\vec{x}_0) + \frac{1}{1!} \vec{\nabla} f(\vec{x}_0) \cdot \vec{h} + \sum_{|\alpha|=2}^N \frac{1}{\alpha!} \frac{\partial^{|\alpha|} f(\vec{x}_0)}{\partial x^\alpha} \cdot \vec{h}^\alpha + \sum_{|\alpha|=N+1} R_\alpha(\vec{x}_0, \vec{h}) \cdot \vec{h}^\alpha$$

oder vereinfacht für 2. Ordnung

$$f(\vec{x}_0 + \vec{h}) = f(\vec{x}_0) + \vec{h} \nabla f(\vec{x}_0) + \underbrace{\left( \frac{h_1^2}{2!} \frac{\partial^2 f}{\partial x_1^2} + \frac{h_2^2}{2!} \frac{\partial^2 f}{\partial x_2^2} + \frac{h_1 h_2}{1!1!} \frac{\partial^2 f}{\partial x_1 \partial x_2} \right)}_{\text{für 2. Ordnung}} + R_{(3,0)}(\vec{x}_0, \vec{h}) \cdot \vec{h}_1^3 + R_{(2,1)}(\vec{x}_0, \vec{h}) \cdot \vec{h}_1^2 \vec{h}_2 + R_{(1,2)}(\vec{x}_0, \vec{h}) \cdot \vec{h}_1 \vec{h}_2^2 + R_{(0,3)}(\vec{x}_0, \vec{h}) \cdot \vec{h}_2^3$$

### 6.3 Jacobi-Matrix

Die Jacobi-Matrix bildet alle ersten Ableitungen einer Funktion ab. Wenn die Jacobi-Matrix quadratisch ist ( $m = n$ ), dann kann dessen Determinante  $\det(J)$  als transformiertes Volumen interpretiert werden:


$$\underbrace{dy_1 dy_2 \dots dy_n}_{\text{„transformiertes Volumenelement“}} = \det(J_f(\vec{x})) \underbrace{dx_1 dx_2 \dots dx_n}_{\text{„Volumenelement“}}$$

$$J_f(\vec{x}) := \begin{bmatrix} \frac{\partial f_1}{\partial x_1}(\vec{x}) & \frac{\partial f_1}{\partial x_2}(\vec{x}) & \dots & \frac{\partial f_1}{\partial x_n}(\vec{x}) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1}(\vec{x}) & \frac{\partial f_m}{\partial x_2}(\vec{x}) & \dots & \frac{\partial f_m}{\partial x_n}(\vec{x}) \end{bmatrix}$$

Die Jacobi-Determinante kann daher auch als ein Mass für Fehlerfortpflanzung sein. Die Berechnung erfolgt direkt über die Determinanten-Regel, über

$$\frac{D(f_1, f_2, \dots, f_n)}{D(x_1, x_2, \dots, x_n)} = \det(J_f(\vec{x})) \quad \text{oder} \quad \det(J_f) = \sqrt{\det \left( \underbrace{J_f^T(\vec{x}) J_f(\vec{x})}_{\text{Diagonalmatrix}} \right)}.$$

Ausserdem gilt für die Transformation  $T$  und deren Inverse  $T^{-1}$ :  $\det(J_T) = \frac{1}{\det J_{T^{-1}}}$



## 7 Numerische Ordinäre Differentialgleichungen

### 7.1 Definitionen

Ordinäre DGL (ODE - ordinary differential equation)

$$y'(x) = f(x, y(x)) \quad \text{mit} \quad y(x_0) = y_0$$

$f(x, y)$  wird auch als r.h.s. Funktion bezeichnet (right hand side).

### 7.2 Explizite Methoden

Es wird vorwärts in der Zeit gerechnet, was keine Solver braucht. Ansatz: Taylor-Approximation. Dies wird aber sehr schnell sehr aufwendig, da schnell höhere Ableitungen in mehrere Dimensionen nötig werden.

$$y(x_0 + h) = y(x_0) + \frac{h}{1!}y'(x_0) + \frac{h^2}{2!}y''(x_0) + \dots + \frac{h^p}{p!}y^{(p)}(x_0) + \underbrace{\frac{h^{p+1}}{(p+1)!}y^{(p+1)}(\xi)}_{\text{Restterm}}$$

Die Herleitung weiterer Ableitungen erfolgt mithilfe der Kettenregel:

$$y''(x) = \frac{\partial f(x, y)}{\partial x}1 + \frac{\partial f(x, y)}{\partial y}f(x, y) = \frac{\partial y'(x)}{\partial x}1 + \frac{\partial y'(x)}{\partial y}y'(x) \quad y'''(x) = \frac{\partial y''(x)}{\partial x}1 + \frac{\partial y''(x)}{\partial y}y'(x) \quad \dots$$

Ableitungen bis zum dritten Grad sind hier aufgelistet (Immenser Rechenaufwand nötig):

$$\begin{aligned} y(x+h) = & y(x) + \frac{f(x,y)}{1!}h + \\ & \frac{1}{2!} \left( \frac{\partial f(x,y)}{\partial x}1 + \frac{\partial f(x,y)}{\partial y}f(x,y) \right) h^2 + \\ & \frac{1}{3!} \left( \frac{\partial^2 f(x,y)}{\partial x^2}1 + 2 \frac{\partial^2 f(x,y)}{\partial x \partial y}f(x,y) + \frac{\partial^2 f(x,y)}{\partial y^2}f(x,y)^2 + \left( \frac{\partial f(x,y)}{\partial y} \right)^2 f(x,y) + \frac{\partial f(x,y)}{\partial x} \frac{\partial f(x,y)}{\partial y} \right) h^3 + \dots + \\ & \frac{1}{4!}y^{(4)}(x)h^4 + \dots + \frac{1}{p!}y^{(p)}(x)h^p + \underbrace{\frac{1}{(p+1)!}y^{(p+1)}(\xi)h^{p+1}}_{\text{Restterm}} \end{aligned}$$

$$\text{Global error} = \max_{0 \leq i \leq k} |y_i - y(x_i)|$$

$$\text{Local error (slope)} = \tau_h(x_n) = \frac{y(x_n+h) - y(x_n)}{h} - \left( \frac{y'(x_n)}{1!} + \frac{y''(x_n)}{2!}h^1 + \dots + \frac{y^{(p)}(x_n)}{p!}h^{p-1} \right)$$

$$h\tau_h(x_n) = y(x_n+h) - y(x_n) - \left( \frac{y'(x_n)}{1!}h^1 + \frac{y''(x_n)}{2!}h^2 + \dots + \frac{y^{(p)}(x_n)}{p!}h^p \right)$$

Assuming that the initial value of the current step is exactly correct, i.e.  $y_n = y(x_n)$

$$h\tau_h(x_n) = y(x_n+h) - \left( y(x_n) + \frac{y'(x_n)}{1!}h^1 + \frac{y''(x_n)}{2!}h^2 + \dots + \frac{y^{(p)}(x_n)}{p!}h^p \right) = y(x_n+h) - y_{n+1}$$

#### 7.2.1 Explizite Euler-Methode

Spezialfall der expliziten Methoden:

Taylor mit Ordnung  $p = 1$

Relativ ungenaue Approximation, da hier die Ableitung pro Schritt unverändert bleibt.

Globaler Fehler:  $\max_{0 \leq i \leq k} |y_i - y(x_i)|$  mit Anzahl Schritten  $k$

Lokaler Fehler:  $y(x_n+h) - y_{n+1}$  wenn Initialwert des aktuellen Schritts ist genau richtig

$$y_0 = y(x_0)$$

$$y(x_0+h) \approx y_1 = y_0 + f(x_0, y_0)h \approx y(x_0) + y'(x_0)h$$

$$y(x_1+h) \approx y_2 = y_1 + f(x_1, y_1)h \approx y(x_1) + y'(x_1)h$$

$$\vdots$$

$$y(x_{n-1}+h) \approx y_n = y_{n-1} + f(x_{n-1}, y_{n-1})h \approx y(x_{n-1}) + y'(x_{n-1})h$$



### 7.2.2 Explizite Taylor-Methoden höherer Ordnung

Wenn  $p > 1$  wird eine bessere Approximation erreicht. Allerdings steigt hier der rechnerische Aufwand enorm. Siehe Section 7.2 für Berechnung.

$$y_0 = y(x_0)$$
$$y_{k+1} = y_k + \frac{y'_k}{1!} h_k + \frac{y''_k}{2!} h_k^2 + \dots + \frac{y_k^{(p)}}{p!} h_k^p$$

### 7.2.3 Explizite Runge-Kutta (RK) Methoden Skript S. 8

Es werden  $s$  rekursive Stages  $k$  definiert, welche zusammenaddiert die Taylor-Approximation ergeben. Hier ist  $s = 4$

$$\begin{aligned}k_1 &= hf(x, y) \\k_2 &= hf(x + mh, y + mk_1) \\k_3 &= hf(x + nh, y + nk_2) \\k_4 &= hf(x + ph, y + pk_3)\end{aligned}$$

$$y(x + h) \approx y(x) + ak_1 + bk_2 + ck_3 + dk_4$$

Im Gegensatz zum Skript (S. 10) sind die  $h$  nicht in den  $k$ -Definitionen enthalten, sondern erst in der finalen Formel. Mit den richtigen Nebenbedingungen (S. 11) entspricht diese Formel dem Taylor Polynom bis zur Ordnung 4

Mit der Gleichsetzung zu Taylor definieren die expliziten RK-Methoden ein überbestimmtes Gleichungssystem mit 8 Gleichungen und 7 Unbekannten  $m, n, p$  und  $a, b, c, d$ .

Es gibt daher verschiedene **Lösungen**, die hier auch für die Ordnung  $s = 2$  und  $s = 4$  aufgeführt sind:

Name der Lösungen      # Stages ( $s$ )      Lösungen

Heun                      2                       $a = b = \frac{1}{2}, m = 1$  ( $n = p = c = d = 0$ )

Explicit Midpoint      2                       $a = 0, b = 1, m = \frac{1}{2}$  ( $n = p = c = d = 0$ )

Klassische Runge-Kutta   4                       $m = n = \frac{1}{2}, p = 1, a = d = \frac{1}{6}, b = c = \frac{1}{3}$

$$\text{Local error (slope)} = \tau_h(x_n) = \frac{y(x_n + h) - y(x_n)}{h} - \left( \frac{\tilde{k}_1 + 2\tilde{k}_2 + 2\tilde{k}_3 + \tilde{k}_4}{6h} \right)$$

the tilde superscript  $\tilde{k}$  indicates that the stage values  $k$  must be evaluated using exact values for  $x, y$

### 7.2.4 Generelles Framework für Runge-Kutta Methoden (Butcher Tableaus) Skript S. 13

$$\left. \begin{aligned}k_1 &= f(x + c_1 h, y + h \sum_{j=1}^s a_{1,j} k_j) \\k_2 &= f(x + c_2 h, y + h \sum_{j=1}^s a_{2,j} k_j) \\k_3 &= f(x + c_3 h, y + h \sum_{j=1}^s a_{3,j} k_j) \\&\vdots \\k_s &= f(x + c_s h, y + h \sum_{j=1}^s a_{s,j} k_j) \\y(x+h) &\approx y(x) + h \left( \sum_{j=1}^s b_j k_j \right)\end{aligned} \right\} s \text{ stages}$$

$$\begin{array}{c|cccccc}0 & 0 & 0 & \cdots & 0 & 0 \\c_2 & a_{2,1} & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\c_s & a_{s,1} & a_{s,2} & \cdots & a_{s,s-1} & 0 \\ \hline & b_1 & b_2 & \cdots & b_{s-1} & b_s\end{array}$$

$a$  = Aufteilung in  $Y$   
 $b^T$  = Lösungen, durch Methode gegeben  
 $c$  = Aufteilung in  $X$

FSAL (First Same As Last)

Spezialform:


$$\begin{array}{c|cccccc}0 & 0 & 0 & \cdots & 0 & 0 \\c_2 & a_{2,1} & 0 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\c_{s-1} & a_{s-1,1} & a_{s-1,2} & \cdots & 0 & 0 \\1 & b_1 & b_2 & \cdots & b_{s-1} & 0 \\ \hline & b_1 & b_2 & \cdots & b_{s-1} & 0\end{array}$$

Bedingungen (Für Explizite Methode):

- $c_i = \sum_{j=1}^s a_{ij} = \sum_{j=1}^{i-1} a_{ij} \quad (i = 2, \dots, s)$
- $\sum_{j=1}^s b_j = 1$
- $c_1 = 0$
- $a_{1j} = 0 \quad 1 \leq j \leq s$
- $a_{ij} = 0 \quad j \geq i$


$\begin{array}{c cc}0 & & \\1/2 & 1/2 & \\1/2 & 0 & 1/2 \\1 & 0 & 0 & 1 \\ \hline & 1/6 & 1/3 & 1/3 & 1/6\end{array}$	$\begin{array}{c c}0 & \\1 & \\ \hline 0 & 1/2 \\0 & 1\end{array}$	$\begin{array}{c cc}0 & & \\2/3 & 2/3 & \\ \hline & 1/4 & 3/4\end{array}$
Classical Runge-Kutta of order 4 (cf. 1.10c)	Explicit Euler method (cf. 1.3A') Explicit Midpoint method (1.9b)	Yet another method (cf. 1.9c)

Heun Methode (RK-2):  $b_1 = b_2 = \frac{1}{2}; c_2 = \frac{1}{2}; a_{2,1} = \frac{1}{2}$



Runge-Kutta 2<sup>ème</sup> ordre :

$$k_2 = h f(x_n + h/2, y_n + k_1/2)$$



Runge-Kutta 4<sup>ème</sup> ordre

### 7.2.5 Adaptive Explizite Methoden Skript S. 17

Idee: Automatische Adaptierung der Step-Size  $h$ . Dies macht eine Definition des maximalen Fehlers der Approximation nötig. Das *Accuracy Goal* ( $ag$ ) gibt die minimal übereinstimmende Anzahl Nachkommastellen an während das *Precision Goal* ( $pg$ ) die Anzahl signifikanter Stellen des Resultats repräsentiert. Der Toleranz-Parameter ist:

$$\varepsilon = \varepsilon_a + |y|\varepsilon_r = 10^{-ag} + |y|10^{-pg} \geq |e|.$$

#### Eingebettete Paare von expliziten Runge-Kutta Methoden

0	0	0	...	0	0
$c_2$	$a_{2,1}$	0	...	0	0
$\vdots$	$\vdots$	$\vdots$	$\ddots$	0	$\vdots$
$c_{s-1}$	$a_{s-1,1}$	$a_{s-1,2}$	...	0	0
$c_s$	$a_{s,1}$	$a_{s,2}$	...	$a_{s,s-1}$	0
	$b_1$	$b_2$	...	$b_{s-1}$	$b_s$
	$\hat{b}_1$	$\hat{b}_2$	...	$\hat{b}_{s-1}$	$\hat{b}_s$

Die Methode führt eine zweite Approximation, eine *eingebettete Ordnung*  $\hat{p}$  ein, welche für die Fehlerrechnung zuständig ist. Die *primäre Ordnung*  $p$  wird benötigt, um die Schrittweite zu berechnen. Meist ist  $\hat{p} = p - 1$ .

Das Butcher-Tableau wird dabei um eine Zeile der  $b$ -Zahlen erweitert.

Lokaler Fehler:

$$e_n = y(x+h) - \hat{y}(x+h) = h_n \sum_{j=1}^s (b_j - \hat{b}_j) k_j \Rightarrow \|e_n\| = \left\| h_n \sum_{j=1}^s (b_j - \hat{b}_j) k_j \right\|$$

Wenn bei aktuellem Schritt  $\frac{\|e_n\|}{\varepsilon} > 1$ , dann war

die Schätzung von  $h_n$  zu optimistisch und der Schritt muss mit kleinerer Schrittweite wiederholt werden (**Reject**).

Ansonsten  $\frac{\|e_n\|}{\varepsilon} \leq 1$  wird fortgesetzt mit dem Update der Step-Size (**Proceed**):

$$h_{n+1} = h_n \left( \frac{\varepsilon}{\|e_n\|} \right)^{\frac{1}{p}} = h_n \left( \frac{\|e_n\|}{\varepsilon} \right)^{-\frac{1}{p}}$$

$$\varepsilon = \varepsilon_a + \varepsilon_r |y_n| \quad \text{mit} \quad \tilde{p} = \min(p, \hat{p}) + 1 \quad (\text{Ordnung des Primärverfahrens})$$

#### Beispiel

$x$	$y$	$h_n$	$\left( \frac{\ e_n\ }{\varepsilon} \right)^{-\frac{1}{p}}$	$h_{n+1}$	Status
10	$[1, -1]^T$	1	0.4	0.4	Reject
10	$[1, -1]^T$	0.4	1.5	0.6	Proceed
10.4	$[0.420958, -1.40852]^T$	0.6	0.5	0.3	Reject

### 7.2.6 Stabilität von expliziten Methoden Skript S. 27

Globaler relativer Fehler darf nicht divergieren, d.h. muss beschränkt sein. Da die Analyse mit zu untersuchender ODE wegen fehlender Kenntnis über die Lösung sehr schwierig ist, wird mit allgemeiner ODE gerechnet, dem Dahlquist Modell:

$$y' = Ay \quad y(0) = 1 \quad \text{mit} \quad A = \Re\{A\} + j\Im\{A\} \in \mathbb{C}$$

Dessen Lösung ist  $y = e^{\Re\{A\}x} (\cos(\Im\{A\}x) + j \sin(\Im\{A\}x))$ , also eine Schwingung mit exponentieller Amplitude  $e^{\Re\{A\}x}$  und Frequenz  $\Im\{A\}$ .

Mit der zu untersuchenden Methode kann eine *lineare Stabilitätsfunktion*  $F(z)$  berechnet werden.

**Beispiel** Anhand der Heun-Methode (RK-2) wird die Untersuchung gezeigt:

$$k_1 = Ay_k$$

$$k_2 = A(y_k + hk_1) = A(y_k + Ah y_k) \quad \Rightarrow$$

$$y_0 = y(x_0) = y(0) = 1$$

$$y_{k+1} = y_k \underbrace{\left( 1 + hA + (hA)^2 \frac{1}{2} \right)}_{F(hA)=F(z), \quad z=hA \in \mathbb{C}}$$


Die lineare Stabilitätsfunktion kann jetzt auch so eingesetzt werden:

$$y_{k+1} = \left( |F(z)| \exp(j \arg(F(z))) \right) y_k$$

Jetzt können drei Fälle unterschieden werden:

- $\Re\{A\} < 0$ : Die Amplitude der ODE wird exponentiell kleiner. Die Stabilitätsbedingung verlangt, dass die approximierten Werte  $y_k$  ( $k = 0, 1, \dots$ ) ebenfalls exponentiell gedämpft werden. Daher und aus  $y_{k+1} \propto |F(z)|$  folgt, dass  $|F(z)| < 1$ .
- $\Re\{A\} = 0$ : Die Amplitude der ODE ist konstant 1. Die Stabilitätsbedingung verlangt, dass die approximierten Werte  $y_k$  ( $k = 0, 1, \dots$ ) ebenfalls konstant sind. Daher und aus  $y_{k+1} \propto |F(z)|$  folgt, dass  $|F(z)| = 1$ .
- $\Re\{A\} > 0$ : Die Amplitude der ODE wird exponentiell grösser. Die Stabilitätsbedingung verlangt, dass die approximierten Werte  $y_k$  ( $k = 0, 1, \dots$ ) ebenfalls exponentiell wachsen. Daher und aus  $y_{k+1} \propto |F(z)|$  folgt, dass  $|F(z)| > 1$ .

Die Fälle 2 und 3 bereiten keine Probleme (Bedingungen sind immer erfüllt), nur die erste Fall ist kritisch.



Fall 1 der Stabilitätsbedingung ( $\Re\{A\} < 0$ ):

$$1 > |F(z)| = |1 + hA + \frac{1}{2}(hA)^2| \Rightarrow -2 < h\Re\{A\} < 0.$$

Fälle 2 und 3 sind in Abb. nicht berücksichtigt.

**Rekursive Formel** S29 Für das Stabilitätspolynom  $F(z) = 1 + b_1k_1(z) + \dots + b_s k_s(z)$  existieren rekursive Formeln:  $k_1(z) = z$ ,  $k_{j+1}(z) = z(1 + a_{j+1,1}k_1(z) + a_{j+1,2}k_2(z) + \dots + a_{j+1,j}k_j(z))$

**Schwäche der expliziten Methoden:** Stabilität!

### 7.2.7 Stiffness (Steifigkeit) Skript S. 33

Definition Stiffness = sehr schwierig (gemäss Wikipedia). Ungefähre Idee: Die expliziten Methoden werden zu inakzeptabel kleinen Step-Sizes gezwungen (Computational complexity). Dies trotz eigentlichen „smoothen“ Oberflächen der Funktionen, die intuitiv nicht sehr schwierig berechenbar sein sollten.

Wenn Stabilitätsverletzungen (Stiffness) detektiert werden, soll zu impliziten Verfahren (Blackbox-Solver) gewechselt werden, um dann mit non-Stiffness-Detektierung zurück zu expliziten Verfahren umzustellen.

Stiffness ist abhängig von:

- Konkrete ODE
- Konkrete Schrittweite  $h$
- Konkretes Verfahren (bspw. RK-4)

**Stiffness Detektierung** Voraussetzung:  $c_{s-1} = c_s = 1$ . Durch Testen von  $\left| h \frac{\partial f(x,y)}{\partial y} \right|$  auf die absolute Grenze der Stabilitätsregion kann Stiffness detektiert werden. Stiffness liegt vor, falls  $|h\tilde{\lambda}|$  ausserhalb oder an der Grenze des Stabilitätsbereiches liegt.

Beispiel explizite Runge-Kutta:

$$k_{s-1} = f\left(x + c_{s-1}h, y + h \underbrace{\sum_{j=1}^s a_{s-1,j}k_j}_{g_{s-1}}\right) \quad k_s = f\left(x + c_s h, y + h \underbrace{\sum_{j=1}^s a_{s,j}k_j}_{g_s}\right) \quad \Rightarrow \quad \tilde{\lambda} = \frac{\|k_s - k_{s-1}\|}{\|g_s - g_{s-1}\|}$$

$\tilde{\lambda}$  ist eine Schätzung für  $f_y = \frac{\partial}{\partial y} f(x,y)$  z.B.  $y' = x^4 - 25y^4 = f(x,y)$  und übernimmt die Rolle von  $\Re\{A\}$  bei der Stabilitätsanalyse.

## 7.3 Systeme von ODEs und ODEs höherer Ordnungen Skript S. 37

Systeme von ODEs werden in Vektor-Notation aufgeschrieben und wie üblich berechnet. That's all.

8    Ableitungstabelle

	$F(x)$	$F'(x)$
Addition	$f(x) \pm g(x)$	$f'(x) \pm g'(x)$
Linearity	$af(x)$	$af'(x)$
Product Rule	$f(x)g(x)$	$f'(x)g(x) + f(x)g'(x)$
Quotient Rule	$\frac{f(x)}{g(x)}$	$\frac{f'(x)g(x)-f(x)g'(x)}{(g(x))^2}$
Chain Rule	$f(g(x))$ $f^{-1}(x)$	$f'(g(x)) \cdot g'(x)$ $\frac{1}{f'(f^{-1}(x))}$
Basic functions	$x^n$ for any real $n$ $e^x$ $a^x$ ( $a > 0$ ) $\ln x$	$nx^{n-1}$ $e^x$ $(\ln a)a^x$ $\frac{1}{x}$
Trig functions	$\sin x$ $\cos x$ $\tan x$ $\arctan x = \tan^{-1} x$ $\arcsin x = \sin^{-1} x$	$\cos x$ $-\sin x$ $\frac{1}{\cos^2 x} = 1 + \tan^2 x$ $\frac{1}{1+x^2}$ $\frac{1}{\sqrt{1-x^2}}$
Hyperbolic Trig	$\sinh x$ $\cosh x$ $\tanh x$ $\sinh^{-1} x$ $\tanh^{-1} x$	$\cosh x$ $\sinh x$ $\frac{1}{\cosh^2 x}$ $\frac{1}{\sqrt{1+x^2}}$ $\frac{1}{1-x^2}$

9    Übersicht der Polynome

Name	Formel	Beispiel	Referenz
Newton	$\pi_n(x) = \prod_{i=1}^n (x - x_{i-1})$	$\pi_2 = (x - x_0)(x - x_1)$	1.3, S. 1
Bernstein	$B_{i,n}(x) = \binom{n}{i}(1-x)^{n-i}x^i$	$B_{1,2} = 2x(1-x)$	4.2.1, S. 8
Monomials	$x^n$	$x^2$	5.1.4, S. 11
Orthogonale	$p_{k,N}(t) = \sum_{i=0}^k (-1)^i \binom{k}{i} \binom{k+i}{i} \frac{t^{(i)}}{N^{(i)}}$	$P_1(x) = 1 - \frac{x-3}{2}$	5.1.5, S. 11
Chebyshev	$T_n(x) = \cos(n \arccos(x))$	$T_2 = 2x^2 - 1$	5.1.6, S. 12

## 10 Integrationstabelle

$$\begin{array}{ll} \text{Linearity} & \int af(x) + bg(x) dx = a \int f(x) dx + b \int g(x) dx \\ \text{Substitution} & \int f(w(x))w'(x) dx = \int f(w) dw \\ \text{Integration by parts} & \int u(x)v'(x) dx = u(x)v(x) - \int u'(x)v(x) dx \end{array}$$

### Basic Functions

$$\begin{array}{ll} \int x^n dx = \frac{x^{n+1}}{n+1} + C & \int \frac{1}{x} dx = \ln |x| + C \\ \int e^{ax} dx = \frac{1}{a}e^x + C & \int a^x dx = \frac{a^x}{\ln a} + C \end{array}$$

### Trigonometric functions

$$\begin{array}{ll} \int \sin x dx = -\cos x + C & \int \cos x dx = \sin x + C \\ \int \frac{1}{\cos^2 x} dx = \tan x + C & \int \tan x dx = -\ln |\cos x| + C \\ \int \cot x dx = \ln |\sin x| + C & \end{array}$$

### Hyperbolic Trig functions

$$\begin{array}{ll} \int \sinh x dx = \cosh x + C & \int \cosh x dx = \sinh x + C \\ \int \tanh x dx = \ln(\cosh x) + C & \int \coth x dx = \ln |\sinh x| + C \end{array}$$

### Functions with $a^2 \pm x^2$

$$\begin{array}{ll} \int \frac{dx}{\sqrt{a^2 - x^2}} = \sin^{-1}\left(\frac{x}{a}\right) + C & \int \frac{dx}{a^2 + x^2} = \frac{1}{a} \tan^{-1}\left(\frac{x}{a}\right) + C \\ \int \frac{dx}{a^2 - x^2} = \frac{1}{2a} \ln \left| \frac{x+a}{x-a} \right| + C & \\ \int \frac{dx}{\sqrt{x^2 - a^2}} = \cosh^{-1}\left(\frac{x}{a}\right) + C & \int \frac{dx}{\sqrt{x^2 + a^2}} = \sinh^{-1}\left(\frac{x}{a}\right) + C \end{array}$$

### Inverse Functions

$$\begin{array}{ll} \int \ln x dx = x \ln x - x + C & \int \arcsin x dx = x \arcsin x + \sqrt{1-x^2} + C \\ \int \arctan x = x \arctan x - \frac{1}{2} \ln(1+x^2) + C & \end{array}$$

## 11 Cheatsheet

### 11.1 Dreiecksformeln

#### Cosinussatz


$$c^2 = a^2 + b^2 - 2 \cdot a \cdot b \cdot \cos \gamma$$

#### Sinussatz

$$\frac{a}{\sin \alpha} = \frac{b}{\sin \beta} = \frac{c}{\sin \gamma} = 2r = \frac{u}{\pi}$$

#### Pythagoras beim Sinus

$$\sin^2(b) + \cos^2(b) = 1 \quad \tan(b) = \frac{\sin(b)}{\cos(b)}$$



$$\sin \beta = \frac{b}{a} = \frac{\text{Gegenkathete}}{\text{Hypotenuse}}$$

$$\cos \beta = \frac{c}{a} = \frac{\text{Ankathete}}{\text{Hypotenuse}}$$

$$\tan \beta = \frac{c}{b} = \frac{\text{Gegenkathete}}{\text{Ankathete}}$$

$$\cot \beta = \frac{c}{b} = \frac{\text{Ankathete}}{\text{Gegenkathete}}$$

### 11.2 Funktionswerte für Winkelargumente

deg	rad	sin	cos	tan	deg	rad	sin	cos	deg	rad	sin	cos	deg	rad	sin	cos
0°	0	0	1	0	90°	$\frac{\pi}{2}$	1	0	180°	$\pi$	0	-1	270°	$\frac{3\pi}{2}$	-1	0
30°	$\frac{\pi}{6}$	$\frac{1}{2}$	$\frac{\sqrt{3}}{2}$	$\frac{\sqrt{3}}{3}$	120°	$\frac{2\pi}{3}$	$\frac{\sqrt{3}}{2}$	$-\frac{1}{2}$	210°	$\frac{7\pi}{6}$	$-\frac{1}{2}$	$-\frac{\sqrt{3}}{2}$	300°	$\frac{5\pi}{3}$	$-\frac{\sqrt{3}}{2}$	$\frac{1}{2}$
45°	$\frac{\pi}{4}$	$\frac{\sqrt{2}}{2}$	$\frac{\sqrt{2}}{2}$	1	135°	$\frac{3\pi}{4}$	$\frac{\sqrt{2}}{2}$	$-\frac{\sqrt{2}}{2}$	225°	$\frac{5\pi}{4}$	$-\frac{\sqrt{2}}{2}$	$-\frac{\sqrt{2}}{2}$	315°	$\frac{7\pi}{4}$	$-\frac{\sqrt{2}}{2}$	$\frac{\sqrt{2}}{2}$
60°	$\frac{\pi}{3}$	$\frac{\sqrt{3}}{2}$	$\frac{1}{2}$	$\sqrt{3}$	150°	$\frac{5\pi}{6}$	$\frac{1}{2}$	$-\frac{\sqrt{3}}{2}$	240°	$\frac{4\pi}{3}$	$-\frac{\sqrt{3}}{2}$	$-\frac{1}{2}$	330°	$\frac{11\pi}{6}$	$-\frac{1}{2}$	$\frac{\sqrt{3}}{2}$


### 11.3 Periodizität

$$\cos(a + k \cdot 2\pi) = \cos(a) \quad \sin(a + k \cdot 2\pi) = \sin(a) \quad (k \in \mathbb{Z})$$

### 11.4 Quadrantenbeziehungen

$$\begin{aligned} \sin(-a) &= -\sin(a) & \cos(-a) &= \cos(a) \\ \sin(\pi - a) &= \sin(a) & \cos(\pi - a) &= -\cos(a) \\ \sin(\pi + a) &= -\sin(a) & \cos(\pi + a) &= -\cos(a) \\ \sin\left(\frac{\pi}{2} - a\right) &= \sin\left(\frac{\pi}{2} + a\right) = \cos(a) & \cos\left(\frac{\pi}{2} - a\right) &= -\cos\left(\frac{\pi}{2} + a\right) = \sin(a) \end{aligned}$$

### 11.5 Ableitungen



### 11.6 Additionstheoreme

$$\begin{aligned} \sin(a \pm b) &= \sin(a) \cdot \cos(b) \pm \cos(a) \cdot \sin(b) \\ \cos(a \pm b) &= \cos(a) \cdot \cos(b) \mp \sin(a) \cdot \sin(b) \\ \tan(a \pm b) &= \frac{\tan(a) \pm \tan(b)}{1 \mp \tan(a) \cdot \tan(b)} \end{aligned}$$

### 11.8 Produkte

$$\begin{aligned} \sin(a) \sin(b) &= \frac{1}{2}(\cos(a - b) - \cos(a + b)) \\ \cos(a) \cos(b) &= \frac{1}{2}(\cos(a - b) + \cos(a + b)) \\ \sin(a) \cos(b) &= \frac{1}{2}(\sin(a - b) + \sin(a + b)) \end{aligned}$$

### 11.9 Euler-Formeln

$$\begin{aligned} \sin(x) &= \frac{1}{2j} (e^{jx} - e^{-jx}) & \cos(x) &= \frac{1}{2} (e^{jx} + e^{-jx}) \\ e^{x+jy} &= e^x \cdot e^{jy} = e^x \cdot (\cos(y) + j \sin(y)) \end{aligned}$$

### 11.7 Doppel- und Halbwinkel

$$\begin{aligned} \sin(2a) &= 2 \sin(a) \cos(a) \\ \cos(2a) &= \cos^2(a) - \sin^2(a) = 2 \cos^2(a) - 1 = 1 - 2 \sin^2(a) \\ \cos^2\left(\frac{a}{2}\right) &= \frac{1 + \cos(a)}{2} & \sin^2\left(\frac{a}{2}\right) &= \frac{1 - \cos(a)}{2} \end{aligned}$$

$$e^{j\pi} = e^{-j\pi} = -1$$

### 11.10 Summe und Differenz

$$\begin{aligned}\sin(a) + \sin(b) &= 2 \cdot \sin\left(\frac{a+b}{2}\right) \cdot \cos\left(\frac{a-b}{2}\right) \\ \sin(a) - \sin(b) &= 2 \cdot \sin\left(\frac{a-b}{2}\right) \cdot \cos\left(\frac{a+b}{2}\right)\end{aligned}$$

$$\begin{aligned}\cos(a) + \cos(b) &= 2 \cdot \cos\left(\frac{a+b}{2}\right) \cdot \cos\left(\frac{a-b}{2}\right) \\ \cos(a) - \cos(b) &= -2 \cdot \sin\left(\frac{a+b}{2}\right) \cdot \sin\left(\frac{a-b}{2}\right) \\ \tan(a) \pm \tan(b) &= \frac{\sin(a \pm b)}{\cos(a) \cos(b)}\end{aligned}$$